

1. Пусть  $\sum p_i = 1$  и все  $p_i > 0$ . Определим функцию  $h(p) = \sum p_i \log \frac{1}{p_i}$ . К чему стремится значение этой функции для следующих последовательностей:

a)  $1/2, 1/4, 1/8, \dots, 1/2^n, 1/2^n$ ;

b)  $1/3, 1/9, 1/9, \dots, 1/3^n, 1/3^n, 1/3^n$ ?

2. Веса 2 монеток выбираются случайно и независимо среди чисел  $1, \dots, 4$ . Какова энтропия Шеннона случайной величины, равной результату сравнения на чашечных весах весов первой и второй монетки?

### Определение 1

Будем называть кодом функцию  $C: \{a_1, \dots, a_n\} \rightarrow \{0, 1\}^*$ , сопоставляющую буквам некоторого алфавита кодовые слова. Если любое сообщение, которое получено применением кода  $C$ , декодируется однозначно (т.е. только единственным образом разрезается на образы  $C$ ), то такой код называется однозначно декодируемым. Код называется префиксным (беспрефиксным, prefix-free), если никакое кодовое слово не является префиксом другого кодового слова.

3. Пусть слова  $c_1, \dots, c_k$  задают префиксный код, и слова  $d_1, \dots, d_\ell$  образуют префиксный код. Докажите, что слова вида  $c_i d_j$  также образуют префиксный код.

4. Докажите, что для любого префиксного кода со множеством кодовых слов  $a_1, \dots, a_n$  выполняется следующее неравенство:

$$\sum_{i=1}^n 2^{-|a_i|} \leq 1.$$

5. Докажите, что если есть набор целых чисел  $\ell_1, \dots, \ell_n$ , удовлетворяющие неравенству

$$\sum_{i=1}^n 2^{-\ell_i} \leq 1,$$

то существует префиксный код с кодовыми словами  $c_1, \dots, c_n$ , где  $|c_i| = \ell_i$ .

### Определение 2 (код Шеннона — Фано)

Отсортируем вероятности,  $p_1 \geq p_2 \geq \dots \geq p_n$ . «Уложим» вероятности  $p_i$  в отрезок  $[0, 1]$ , получая таким образом точки

$$0 \leq p_1 < p_1 + p_2 < \dots < p_1 + p_2 + \dots + p_n \leq 1.$$

Разобьём интервал пополам, и скажем, что все коды, отвечающие точкам слева от разреза, начинаются с нуля, а точкам справа — с единицы. Если отрезок пересекает разрез, и он самый левый (первый), то соответствующий код начинается с 0; если отрезок пересекает разрез и он самый правый (последний), то код начинается с 1. Иначе выбираем ноль или единицу произвольным образом. Продолжаем рекурсивно этот процесс, пока в интервале не останется ровно один отрезок.

6. Докажите, что:

- а) код Шеннона — Фано является префиксным;
  - б) если центральный отрезок относить туда, куда попала его большая часть, то кодирование Шеннона — Фано не является сбалансированным (то есть не существует константы  $d$ , для которой выполнено  $\ell(c_i) \leq -\log p_i + d$  для любых  $k$  и любых исходных вероятностей  $p_1, \dots, p_k$ );
  - с) если центральный отрезок всегда относить к правой половине, то кодирование Шеннона — Фано также не является сбалансированным.
7. Приведите пример такого распределения вероятностей, что код Шеннона–Фано не является оптимальным.

### Определение 3 (Арифметическое кодирование)

Назовём стандартным интервалом интервал вида  $[0.v0, 0.v1)$ , где  $v$  — некоторая последовательность битов. Уложим вероятности  $p_i$  в отрезок  $[0, 1]$ , получаются точки

$$0 \leq p_1 < p_1 + p_2 < \dots < p_1 + p_2 + \dots + p_n \leq 1.$$

Пусть  $(0.v_i0, 0.v_i1)$  — максимальный стандартный интервал в отрезке

$$[p_1 + p_2 + \dots + p_{i-1}, p_1 + p_2 + \dots + p_i].$$

Тогда сопоставим  $i$ -ой букве код  $v_i0$ . Легко заметить, что код получился префиксным, так как если  $v_i$  является префиксом  $v_j$ , то интервал  $(0.v_j0, 0.v_j1)$  вложен в интервал  $(0.v_i0, 0.v_i1)$ , а такого при построении  $v_i$  не может произойти.

8. Докажите, что арифметическое кодирование сбалансировано с константой 2.

